

[Day 2 종합 실습]

End2End 데이터 분석 프로젝트

실습 결과 보고서

작성자: 광주 1반 5조

제출 일자: 2026-07-21

실행 결과 화면 캡처본

```
data-project/another_day2 on main [?] via v3.11.15 (.venv)
> python End2End_Analysis.py

=====
🚀 [STEP 1] 데이터 로드 및 정제 (Pandas vs Polars 양방향 비교)
=====

[+] Pandas (32561, 15) vs Polars (32561, 15) | shape 일치: True
[+] 결측치 인식: 4,262건 (workclass/occupation/native-country)
[+] 정제 완료 | 결측·중복 2,422건 제거 -> 30,139행 확정

=====
🚀 [STEP 2] 기술통계 · 상관분석 · 통계 검정
=====

[기술 통계]
   age  education-num  hours-per-week  capital-gain  capital-loss
count  30139.00      30139.00      30139.00      30139.00      30139.00
mean    38.44         10.12         40.93       1092.84         88.44
std     13.13          2.55         11.98       7409.11        404.45
min     17.00          1.00          1.00          0.00          0.00
25%     28.00          9.00         40.00          0.00          0.00
50%     37.00         10.00         40.00          0.00          0.00
75%     47.00         13.00         45.00          0.00          0.00
max     90.00         16.00         99.00      99999.00      4356.00

[-] 교육-소득 상관계수: 0.3354
[-] 교육-근무 상관계수: 0.1528
[-] 한계 상승률(Slope): 교육 1년 추가 시 고소득 진입 확률 평균 4.74%p 상승

=====
🚀 [STEP 3] 이중축(Dual-axis) 시각화 4종 렌더링 (Seaborn & Plotly)
=====

[1/4] seaborn_edu_vs_income.png 저장 완료
[2/4] plotly_edu_vs_income.html 저장 완료
[3/4] seaborn_edu_vs_hours.png 저장 완료
[4/4] plotly_edu_vs_hours.html 저장 완료

=====
🚀 [STEP 4] 머신러닝 Pipeline 모델 학습 및 저장
=====

[+] Model Accuracy : 0.7809
[+] Model F1-Score(weighted) : 0.7712

=====
🚀 [STEP 5] 분석 리포트(report.md) 자동 생성
=====

[+] 'report.md' 자동 생성 완료

=====
✅ [SUCCESS] 전체 분석 파이프라인이 완료되었습니다.
=====
```

git commit 로그 캡처본

```
data-project/another_day2 on ⑦main [?] via ② v3.11.15 (.venv) took 2s
> git log --oneline -6
3360b55 (HEAD -> main, origin/main, origin/HEAD) rename: 실습 번호 맞춰서
229da74 practice_4 시각화 구현
c4a4164 day2_실습 3 구현
08db250 day_2 init
597e557 refactor: 폴더 구조 변경
6341393 Day1 종합실습 : 실행결과 정리 문서 추가 (화면 캡처·보고서·PDF)
```

1. 실습 개요

▣ 프로젝트 목적

미국 성인 인구조사(Adult Census Income) 데이터를 활용하여 데이터 수집·정제부터 통계 분석, 머신러닝 모델링, 시각화 및 리포트 자동 생성까지 데이터 분석의 전 과정(End-to-End)을 통합적으로 수행하고 비즈니스 인사이트를 도출합니다. 특히, 인적 자본(교육 연수)과 근로 시간이 고소득(>50K) 달성에 미치는 영향을 통계적으로 검증하는데 초점을 맞춥니다.

▣ 사용 데이터 및 기술 스택

- 데이터셋: Adult Census Income (분석 타겟: 소득 5만 달러 초과 여부)
- 핵심 기술: Python, Pandas, Polars, Scikit-Learn, SciPy, Seaborn, Plotly

▣ 주요 수행 프로세스

- **Step 1: 데이터 로드 및 정제 (크로스 체크)**
 - Pandas와 Polars를 모두 활용해 데이터를 로드하고 처리 방식을 비교합니다.
 - 결측치와 중복 데이터를 제거하여 데이터 무결성을 확보합니다.
- **Step 2: 통계 검정 및 인사이트 도출**
 - 상관분석 및 T-test: 교육 연수와 소득, 근무 시간 간의 상관관계를 파악하고 두 소득 집단 간의 학력 차이가 통계적으로 유의미한지 검증합니다.
 - 선형회귀 분석: 교육 연수가 1년 증가할 때 고소득 진입 확률이 얼마나 상승하는지(한계 상승률) 수치화합니다.
- **Step 3: 이중축(Dual-axis) 시각화 렌더링**
 - 막대 차트(인구수 볼륨)와 꺾은선 차트(고소득자 비율 및 평균 근무시간 추이)를 결합한 고도화된 이중축 차트를 생성합니다.

- Seaborn을 이용한 정적 차트 2종, Plotly를 이용한 인터랙티브 차트 2종을 각각 출력합니다.
- **Step 4: 머신러닝 파이프라인(Pipeline) 구축**
 - Scikit-Learn의 ColumnTransformer(표준화 및 원핫인코딩)와 RandomForestClassifier를 엮은 파이프라인을 구축합니다.
 - 정확도(Accuracy)와 가중 F1-Score를 통해 모델을 평가하고 아티팩트(.joblib)로 저장합니다.
- **Step 5: 분석 리포트 자동화**
 - 위 모든 과정에서 도출된 기술통계, 검정 결과, 머신러닝 성능 지표, 해석 코멘트를 종합하여 읽기 쉬운 비즈니스 문서(report.md)로 자동 발행합니다.

□ 최종 산출물

- 시각화 이미지/웹 파일: seaborn_edu_vs_income.png, plotly_edu_vs_income.html, seaborn_edu_vs_hours.png, plotly_edu_vs_hours.html
- ML 모델 파일: adult_income_pipeline.joblib
- 자동 생성 리포트: report.md

2. 개인 의견 (개선 사항 및 코드 품질 개선 측면)

□ 나용성

1. 코드 검토 및 개선 과정

채택된 코드를 검토하면서 개선점을 찾아 반영했다. 가장 핵심은 결측치 처리였다. 원본에서 ?로 표기된 결측을 na_values="?"(앞 공백 포함)로 지정해, 실제로는 결측이 0건으로 인식되지 않던 문제를 발견했다. skipinitialspace=True가 공백을 먼저 제거하기 때문에 na_values="?"로 고쳐야 4,262건의 결측이 제대로 잡힌다는 점을 확인하고 수정했다. "코드가 돌아간다"와 "데이터가 제대로 처리된다"는 다르다는 걸 체감한 부분이다.

2. 채점 기준 대비 보완

기준에 포함된 기술통계(평균·표준편차·분위수)가 누락되어 describe()를 추가했고, Polars가 pl.from_pandas 변환에만 그쳐 있어 원본을 독립적으로 로딩해 Pandas와 shape를 비교하도록 보강했다.

3. 리포트 품질 개선

자동 생성 리포트가 과도한 전문 용어로 채워져 가독성이 떨어졌다. 분석의 본질(교육-소득 상관 0.34, t-test 유의성, 예측 성능 0.78)은 유지하되 사실 중심의 담백한 리포트로 정리해 누구나 읽기 쉽게 만들었다.

4. 추가 개선 아이디어 (코드 품질 측면)

- 시각화가 '교육 연수' 축에 집중되어 있어, 성별·결혼상태·직업 등 다른 변수로 확장하면 더 다양한 결론을 도출할 수 있다.

- 결측을 행 삭제(dropna, 약 2,400행 손실) 대신 대치(imputation)로 처리하면 데이터 손실을 줄일 수 있다.

- 이중축 차트는 직관적이지만 두 축의 스케일 차이로 해석이 왜곡될 수 있어, 목적에 따라 단일 축 분리도 고려할 만하다.

5. 느낀 점

AI로 생성한 코드라도 그대로 제출하기보다 채점 기준과 데이터 특성에 맞게 검증·수정하는 과정이 중요함을 배웠다. 앞으로 더 사람만이 개입할 수 있는 영역에 강점을 가지도록 더욱 연습 해야겠다고 느꼈다.

▣ 최재은

1. 코드 분석 및 검토 과정

Adult Census Income 데이터를 처음 접하면서 각 컬럼의 의미와 분석 목적을 이해하는 데 집중했다. 단순히 코드를 실행하는 것에서 끝내지 않고, 결측치·중복 데이터가 제대로 처리됐는지와 **Pandas·Polars**의 로딩 결과가 일치하는지를 확인했다. 또한 **income**이 연 소득 5만 달러 초과 여부를 나타내는 목표 변수라는 점을 이해하고 분석 결과를 해석하려고 노력했다.

2. 채점 기준 대비 보완

채점 기준과 코드를 비교해 기술통계, 상관계수, t-test와 p-value 해석, Pipeline 및 모델 저장 여부를 확인했다. 이 과정에서 상관계수 출력이 누락된 것을 발견해 보완했으며, 정확도만으로는 불균형 데이터의 모델 성능을 충분히 판단하기 어려워 **F1 점수**도 함께 확인했다.

3. 시각화 개선

정적 차트와 **Plotly** 차트에 교육 수준별 고소득자 비율이 중복으로 표현된 점을 확인했다. 중복을 줄이기 위해 정적 교육 그래프를 상관관계 히트맵으로 변경하고, 나이 분포는 소득 그룹별 인원 차이의 영향을 줄이도록 밀도 기준으로 수정했다. 그래프마다 같은 소득 그룹에는 동일한 색상을 사용해 일관성과 가독성을 높였다.

4. 추가 개선 아이디어

- 교육뿐만 아니라 직업, 결혼 상태 등 다양한 범주형 변수도 분석할 수 있다.
- 결측 데이터를 모두 삭제하지 않고 대치하는 방법을 비교하면 데이터 손실을 줄일 수 있다.
- **Logistic Regression**과 **Random Forest** 등 여러 모델의 성능을 같은 기준으로 비교할 수 있다.
- 교차검증과 하이퍼파라미터 조정을 적용하면 모델의 안정성과 성능을 개선할 수 있다.

5. 느낀 점

처음에는 기술통계, 상관계수, **t-test**, **F1** 점수 등의 의미를 이해하기 어려웠지만, 결과를 하나씩 해석하면서 데이터 분석의 전체 흐름을 조금씩 이해하게 됐다. 특히 코드가 오류 없이 실행되는 것뿐만 아니라 분석 목적에 맞는지, 그래프가 중복되지 않는지, 결과를 올바르게 해석했는지 확인하는 과정도 중요하다는 것을 배웠다. 앞으로는 코드를 단순히 사용하는 데 그치지 않고, 각 코드가 왜 필요한지 설명할 수 있도록 계속 연습하고 싶다.

▣ 서혁인

1. 코드 선정 과정에서 느낀 점

각자 개발한 결과물을 시각화 가독성 기준으로 비교했는데, 채택된 코드는 볼륨과 비율을 한 화면에서 보는 이중축 구성이 직관적이라는 점에서 강점이 있었다. 여러 접근을 비교하며 "같은 데이터도 표현 방식에 따라 전달력이 크게 달라진다"는 걸 배웠다.

2. 분석 결과에 대한 해석

교육 연수와 소득의 상관계수(**0.34**)와 **t-test** 결과(**p<0.05**)를 보면, 학력이 고소득에 유의미하게 기여함을 통계적으로 확인할 수 있었다. 다만 교육-근무시간 상관은 약해, 소득이 '오래 일하기'보다 '학력에 따른 노동의 질'에 좌우된다는 해석이 인상적이었다.

3. 코드 품질 관점 의견

전처리·통계·시각화·모델·리포트가 단계별(**STEP**)로 잘 나뉘어 있어 흐름을 따라가기 쉬웠다. 다만 결측 처리를 삭제 대신 대치(**imputation**)로 하면 데이터 손실을 줄일 수 있고, 시각화를 성별·결혼상태 등으로 확장하면 결론이 더 다양해질 것이라 생각한다.

4. 협업에서 배운 점

개인이 만든 것을 팀 기준으로 검증·통합하는 과정에서, 채점 기준 체크와 상호 코드 리뷰의 중요성을 느꼈다.

▣ 양소현

다양했던 데이터 종류들과 소득 간의 상관 관계 값을 보거나 데이터 종류들 간의 상관관계 값을 통해서, 데이터들 간에 관련이 깊은 정도의 우위를 보는 것도 좋을 것 같습니다. 특정 부분을 깊게 보기 전에, 어떤 분석을 할 수 있을지 생각할 때 참고할 용도로도 좋을 것 같습니다. 또한 초반에 깊게 들어가기 전에 데이터에 대해 전체적으로 보면서 가중을 인지하기에도 좋은 것 같습니다.

교육 연수(**X축**)와 주당 근무 시간(**Y축**)의 인터랙티브 상관 분석 자료(소득 수준에 따른 데이터들이 표시돼있음)를 보던 중에, 교육 연수와 소득 수준 각각이 주당 근무 시간과 영향이 있을 수도 있겠단 생각이 들었습니다.

쌓은 지식을 기반으로 좋은 회사에 들어갔다거나, 그 지식을 기반으로 시간을 효율적으로 활용하여서 근무 시간이 줄어들 수도 있습니다. 반면 그 높은 수준의 전문지식을 유지하기 위해 일의 품질이든 열심히 일하면서 근무 시간이 더 길 수도 있습니다. 또한 더 노력해서 상승하려고 한 사람들이 공부를 더 많이 했던 사람들에서 확률이 더 높기에 상승하려는 마음으로 오히려 여전히 근무 시간이 길 수도 있습니다. 이처럼 반대 방향으로 영향을 주는 그룹의 경우들이 다양하기에 어떤 결과일지 궁금했습니다. 저런 것들이 상쇄가 돼서 비슷한 정도일 수도 있습니다.

여러 가능성이 가능하기에, 소득을 결과로 보곤했던 것과는 다른 새로운 측면의 분석도 생각해볼 수 있던 좋은 데이터 종류들의 선정이었습니다. 처음에 전체적으로(목차) 본 후에는 자세히 보아야만 알 수 있는 것들(설명)이 있듯, 선정된 몇 요소들의 복합적 관계를 더 알 수 있었습니다.

데이터의 항목이 여러가지이고 소득과 통계적으로 유의미한 상관 관계가 있는 요소들이 여러 가지가 있기에 그러한 다른 것들에 대한 자료도 있으면 좋을 것 같습니다. 분석을 더 길게 설명하진 않더라도 보는 사람이 그 데이터를 통해 새로운 분석이나 인사이트를 얻을 수 있기 때문입니다. 수치를 통해 원본데이터로 바로는 알 수 없던 것들을 알아낼 수 있는 새로운 데이터를 확보할 수 있습니다.

▣ 종합 의견

이번 프로젝트는 **Adult Census Income** 데이터를 대상으로 데이터 준비 → 통계 분석 → 머신러닝 → 리포트 자동화까지 **End2End** 흐름을 팀 단위로 완성한 작업이었다. 각자 개발한 결과물을 시각화 가독성 기준으로 비교·선정하고, 선정된 코드를 함께 검토·보완하는 과정을 거쳤다. 팀원들의 의견을 종합하면 다음과 같은 공통된 방향이 도출되었다.

1. 분석 변수의 다양화와 '전체 조망'의 필요성

팀 전원이 공통적으로, 분석이 '교육 연수' 축에 집중된 점을 아쉬워하며 성별·결혼상태·직업 등 소득과 유의미한 다른 변수로의 확장을 제안했다. 특히 세부 분석에 앞서 변수 간 상관관계를 전체적으로 조망(**overview**) 하면, 어떤 분석이 가능한지 방향을 잡고 데이터의 비중을 먼저 파악하는 데 유용하다는 의견이 있었다. 깊이 있는 분석 이전에 '목차'처럼 전체를 훑는 단계의 가치를 보여준다.

2. 다변수 복합 관계라는 새로운 분석 관점

소득을 항상 '결과'로만 두던 관점에서 벗어나, 교육·소득·근무시간이 서로 어떻게 얽히는지에 대한 문제 제기가 있었다. 예컨대 높은 학력이 효율을 높여 근무시간을 줄일

수도, 전문성 유지나 상승 욕구로 오히려 늘릴 수도 있으며, 이런 상반된 효과가 상쇄될 가능성도 있다. 데이터 선정이 좋아 단순 인과를 넘어 복합적 관계를 탐구할 여지를 열어주었다.

3. 데이터 전처리와 검증의 중요성

결측치가 실제로는 인식되지 않던 문제를 발견·수정한 경험을 통해, "코드가 실행된다"와 "데이터가 올바르게 처리된다"는 다르다는 점을 팀 전체가 체감했다. 생성형 AI로 초안을 빠르게 만들 수 있지만, 데이터 특성과 채점 기준에 맞춘 검증·수정이 반드시 필요하다는 공감대가 형성되었다.

4. 향후 고도화 방향

- 시각화: 이중축 차트는 직관적이나 수치가 겹쳐 정확한 판독이 어려운 경우가 있어, 명확한 수치 표기나 변수별 개별 차트를 병행할 필요가 있다.
- 전처리: 결측을 행 삭제 대신 대치(imputation)로 처리해 데이터 손실을 줄인다.
- 모델: 하이퍼파라미터 튜닝과 추가 변수 투입으로 예측 성능을 개선한다.
- 리포트: 여러 변수의 상관·통계 결과를 함께 제시해, 읽는 사람이 스스로 새로운 인사이트를 얻도록 한다.

맺음말

개인 작업을 팀 기준으로 검증·통합하며 상호 코드 리뷰와 채점 기준 점검의 중요성을 배웠다. 이번 프로젝트는 결과 도출뿐 아니라, '어떤 분석을 왜 하는가'를 함께 고민한 과정에서 의미가 컸다.